

Rapport de TP 4MMAOD : Patch optimal entre deux fichiers

BOYER Quentin (groupe étudiant₁)

7 novembre 2019

1 Graphe de dépendances (1 point)

Dessinez le graphe de dépendances des appels.

L'algorithme est alors de trouver le plus court chemin depuis un point (i, j) $tqi = 0$ et/ou $j = 0$. Cela donne donc en fonction du chemin le patch optimal

2 Principe de notre programme (1 point)

Pour pouvoir trouver le plus court chemin je commence par créer une liste de tout les chemins au départ d'un des bords avec $i = 0$ ou $j = 0$. Ensuite on fait un tas avec ces chemins. A chaque iteration suivante on prends le chemin le plus court, on l'enleve du tas. Grace a ce chemin on produit trois chemins en incrementant i, j puis i et j . Si un chemin $c1$ arrive sur une case sur laquelle un autre chemin est deja passe, on sait par notre invariant qu'il existe un autre moyen d'arriver a ce point, et qu'il est plus court. On peut donc supprimer $c1$, puisque il sera pire que le chemin qui est deja passe par la. Sinon on ajoute le chemin dans notre tas

On s'arrete des que le plus court chemin arrive sur la case (m, n) . On a alors trouve le plus court chemin pour arriver au patch optimal

De plus pour calculer les couts on stocke non pas un tableau des lignes mais un tableau qui donne l'indice de la fin de la ligne i , cela permet ainsi d'avoir un cout faible pour trouver la longueur d'une ligne

3 Analyse du coût théorique (3 points)

On commence par calculer la liste des indices de fin de ligne, ça coute $m + n$ dans tout les cas.

3.1 Nombre d'opérations en pire cas :

Justification : Dans le pire cas il faut calculer tout les chemins possibles, c'est a dire passer par chaque case exactement une fois, cela fait donc $m \times n$ iterations. A chaque iteration on produit environ 1 chemin, puisque si rentre en collision avec les autres chemins, au total on est donc en $\Theta(m \times n)$

3.2 Place mémoire requise :

Justification : Dans chaque case on doit stocker de quelle cases viens t'on, pour pouvoir refaire le chemin dans le sens inverse. Cela fait donc dans le pire cas autant de place requise que de chemins, soit $\Theta(m \times n)$.

3.3 Nombre de défauts de cache sur le modèle CO :

Justification : Pour les défauts de cache, dans le pire cas a chaque fois qu'on essaye d'accéder a une case elle n'est pas dans le cache, si par exemple les chemins les plus courts sont dans des parties totalement differentes de la grille. Cela coute donc $\Theta(m \times n)$

3.4 Quand arrive le pire cas

Si les fichiers ne sont pas tres differentes on va rester majoritairement autour de la diagonale. Cela change donc beacoup la donne, puisque on va faire des défauts de cache que lorsque on a trop avance dans la diagonale, on va calculer et garder en memoire qu'environ la diagonale.

Si $m \approx n$ on a la diagonale de longueur m , cela donne donc un algorithme quasiment lineaire en la taille des fichiers, et m/L défauts de cache environ

4 Compte rendu d'expérimentation (2 points)

4.1 Conditions expérimentales

4.1.1 Description synthétique de la machine :

Le CPU de la machine est un AMD Ryzen 2600, avec 16GB de RAM DDR4. Il tourne sur Arch Linux, i3. Utilisation standard du PC avec des logiciels usuels d'ouvert comme un navigateur web.

4.1.2 Méthode utilisée pour les mesures de temps :

J'ai utilisé le benchTester pour relever les temps de chaque benchmark, user puisque c'est un programme mono-thread et que cela enlève le temps de l'OS. l'un après l'autre en attendant. J'ai recommencé 5 fois.

4.2 Mesures expérimentales

	coût du patch	temps min	temps max	temps moyen
benchmark_00	10419	0.01	0.03	0.02
benchmark_01	13222	5.00	5.99	5.27
benchmark_02	3633	3.00	3.40	3.09
benchmark_03	19121	6.56	7.15	6.73
benchmark_04	3726	3.13	3.32	3.22

FIGURE 1 – Mesures des temps minimum, maximum et moyen de 5 exécutions pour les benchmarks.

On voit en annexe un graphe de temps de calcul en fonction de la taille de fichier, avec des fichiers qui diffèrent avec environ 30% de probabilité par ligne

4.3 Analyse des résultats expérimentaux

On voit avec le graphe en annexe que le temps semble en effet être entre quadratique et linéaire.

5 Coût du patch en octet (1 point)

Il suffit juste de changer la fonction de coût en disant que cela coûte aussi cher de supprimer que d'ajouter, et quasiment deux fois plus cher de faire une substitution. Le coût est alors approximativement la longueur de la ligne somme avec le nombre de chiffres pour représenter le numéro de la ligne. Cela change peu le problème.

6 Bonus : Pourrait-on utiliser une technique de blocking? (1 point)

Avec l'algorithme tel que présenté non, en effet on risque de ne pas trouver le chemin optimal puisque l'algorithme ne sait que aller dans le coin d'un bloc. Pour faire du blocking ça serait de couper les fichiers en parties de plus en plus petites et essayer de transformer chacune des parties d'entrée en chacune des parties d'entrées. Le coût de recoller chaque partie risque de s'avérer assez haut

Annexe




FIGURE 2 – Mesures des temps minimum en fonction de la longueur